

基于高斯混合隐马尔科夫模型的高速公路超车行为辨识与分析^{*}

吕 岸¹, 胡振程², 陈 慧¹

(1. 同济大学汽车学院, 上海 201804; 2. 熊本大学自然科学研究科, 日本熊本 8600862)

[摘要] 基于驾驶模拟器实验数据, 结合高斯混合隐马尔可夫模型(GM-HMM), 对高速公路的超车行为进行辨识, 并对驾驶员意图和超车行为是否正常进行分析。结果表明, 基于GM-HMM的辨识方法能有效辨识多种驾驶工况下的不正常超车行为。

关键词: 高速公路; 超车行为; 高斯混合隐马尔可夫模型

Recognition and Analysis on Highway Overtaking Behavior Based on Gaussian Mixture Hidden Markov Model

Li An, Hu Zhencheng & Chen Hui

1. College of Automotive Engineering, Tongji University, Shanghai 201804

2. Graduate School of Science and Technology, Kumamoto University, Kumamoto, Japan 8600862

[Abstract] Based on experimental data from driving simulator and using Gaussian Mixture Hidden Markov Model (GM-HMM), the overtaking behavior on highway is recognized and whether the drivers' intention and their overtaking behavior are normal or not are analyzed. The results show that by using the method based on GM-HMM, abnormal overtaking behaviors under various driving conditions can be effectively detected.

Keywords: highway; overtaking behavior; Gaussian mixture hidden Markov model

前言

车辆在高速公路上行驶时换道超车较为频繁。据交管部门统计数据显示, 超车引发的交通事故占高速公路交通事故总数的近 20%, 而其中由于驾驶员疲劳和误操作等人为因素造成的事故占到近 70%^[1]。

在高速公路超车问题上, 很多学者提出了建立智能超车系统的方法, 如基于 Backstepping 控制算法选取 Lyapunov 函数设计智能车辆换道及超车轨迹跟踪控制器的方法^[2]和模糊控制器设计方法^[3]。但是在人工智能还不成熟的条件下, 利用建立智能超车系统来减少超车事故还存在一定困难。此外, 也有学者根据危险估计对超车行为做出决策分析,

找出最适合超车的安全区域, 如基于最小安全报警距离的危险估计算法^[4]。但是在找到超车的安全区域后将采用何种控制方式来实现安全超车并没有提及。本文中在分析前人研究成果的基础上, 提出了一种基于高斯混合隐马尔可夫模型 (Gaussian mixture hidden Markov model, GM-HMM) 来辨识超车行为的方法, 用来判断驾驶员是否为正常超车, 有助于对不正常超车的驾驶员给予及时的警告或者辅助纠正, 避免了系统的复杂性, 同时又能起到减少超车事故的作用。

1 高斯混合隐马尔可夫模型

一般认为人的行为动作是人的一系列精神意识的外在反应^[5]。就换道行为而言, 有以下一系列内

* 上海市科学技术委员会基金项目 (07d05901) 和天合汽车研发 (上海) 有限公司资助。

原稿收到日期为 2010 年 5 月 6 日, 修改稿收到日期为 2010 年 5 月 17 日。

在过程: (1)在当前车道的换道准备; (2)换道开始; (3)换道; (4)换道结束; (5)在新车道中的回正。可以认为, 每个过程为这种行为的一个状态, 不可见的过程就是内在的状态, 而驾驶员动作和车辆姿态等就是随时间变化而呈现出来的一系列外在的可见观察序列。还可以看到, 这样一种内在的状态不仅可以呈现出相应的外在观察序列, 并具有一定的传递至下一种内在状态的概率, 比如在执行开始换道后, 驾驶员可以继续执行换道也可以临时改变主意, 反打转向盘进而执行车道保持行为, 所以说, 内在状态间的传递总是存在一定概率。了解行为的内在状态和外在观察序列, 对于超车这种由一系列内在复杂状态组成的行为, 完全可以利用其外在观察序列来对其进行辨识, 而隐马尔可夫模型 (hidden Markov model HMM)就是这样一种通过外在观察序列辨识内在不可见状态的很好方法。

隐马尔可夫模型^[9]是可见马尔可夫模型的延伸和发展。它是一种用参数表示的用于描述随机过程统计特性的概率模型, 是一个双重随机过程。它由马尔可夫链和一般随机过程两个部分组成 (见图1)。其中马尔可夫链用转移概率矩阵描述状态的转移; 而一般随机过程则用观察概率矩阵描述状态与观察序列间的关系。




图1 HMM组成示意图

HMM定义如下。

(1) X 代表一组状态集合, $X = \{S_1, S_2, \dots, S_N\}$, 状态数为 N 并用 q 表示 t 时刻的状态。

(2) O 代表一组可观察序列的集合 $O = \{V_1, V_2, \dots, V_M\}$, 其中 M 是从每一状态可能输出的不同观察值数目。

(3) 状态转移概率矩阵 $A = \{a_{ij}\}$, 这里 $a_{ij} = P\{q_{t+1} = S_j | q_t = S_i\}$, $1 \leq i, j \leq N$ 。

(4) 状态的观察概率矩阵 $B = \{b_i(k)\}$, 表示状态 i 输出相应观察值的概率, 其中 $b_i(k) = P\{O_t = V_k | q_t = S_i\}$, $1 \leq i \leq N, 1 \leq k \leq M$ 。

(5) 初始化状态分布 $\pi = \{\pi_i\}$, $\pi_i = P\{q_1 = S_i\}$, $1 \leq i \leq N$ 。

由上, HMM可以定义为一个五元组 λ :

$$\lambda = (X, Q, \pi, A, B) \quad (1)$$

常常简写为

$$\lambda = (\pi, A, B) \quad (2)$$

HMM主要解决评估问题、解码问题和学习问题。相应的算法为前向后向算法, Viterb算法和 Baum-Welch算法。

由于车辆运动及驾驶行为是一个时间连续的行为, 对于连续的观察序列, 采用结合高斯混合的方法^[9], 即 GM-HMM。此时 GM-HMM参数仍可记为 $\lambda = (\pi, A, B)$, 但是其中的 B 不再是一个矩阵, 而是一组观察值概率密度函数, 即

$$B = \{b_i(O_t) | i = 1, 2, \dots, N\}$$

用公式描述为

$$b_i(O_t) = \sum_{k=1}^M \zeta_k b_{ik}(O_t) = \sum_{k=1}^M \zeta_k N(Q | \mu_{ik}, \sum_{j=1}^J \sigma_{ijk}) \quad 1 \leq i \leq N \quad (3)$$

式中: $N(Q | \mu_{ik}, \sum_{j=1}^J \sigma_{ijk})$ 为多维高斯概率密度函数,

$$N(Q | \mu_{ik}, \sum_{j=1}^J \sigma_{ijk}) = \frac{1}{(2\pi)^{\frac{1}{2}} |\sum_{j=1}^J \sigma_{ijk}|^{\frac{1}{2}}} \cdot e^{-\frac{1}{2} (Q - \mu_{ik})^T (\sum_{j=1}^J \sigma_{ijk})^{-1} (Q - \mu_{ik})} \quad (4)$$

式中: μ_{ik} 为其均值矢量; $\sum_{j=1}^J \sigma_{ijk}$ 为方差矩阵; M 为组成 $b_i(O_t)$ 的高斯混合数目; ζ_k 为组合系数, 即权重, 且 $\sum_{k=1}^M \zeta_k = 1, \zeta_k \geq 0$ 。

于是 GM-HMM可以表示为

$$\lambda = (\pi, A, \zeta, \mu, \sum) \quad (5)$$

2 实验平台

实验平台采用 Honda驾驶模拟器 (图2)。它能为驾驶员提供逼真的驾驶环境, 并能实时输出车辆运行数据如车辆位置、速度和加速度等, 驾驶员操纵数据如转向盘转角、油门开度、转向灯状态等以及周围环境中其他车辆的位置信息。数据采集频率为 100 Hz。实验道路为双车道的高速公路。实验中, 对 5名驾龄在 2~5年、年龄在 20~30岁的驾驶员进行




图2 Honda驾驶模拟器

了驾驶数据采集。驾驶过程中要求他们以自己的驾驶习惯在某一双车道的高速公路路段上驾驶4次,除了进出高速路口和一些大弯道,车速均维持在100 km/h左右,每人持续驾驶时间约为30 min。

3 超车行为的辨识与分析

行为辨识的主要步骤为:首先辨识出该行为是一种换道行为,在靠左侧行驶的国家(如日本)是右换道行为,而在靠右侧行驶的国家(如中国)是左换道行为(由于本次实验数据在日本采得,超车行为均为右换道行为);与此同时,判断前方行车道内是否有车辆,如果有,则认为是超车行为。因此,首要任务是右换道行为的辨识。利用GM-HMM的辨识过程如图3所示。

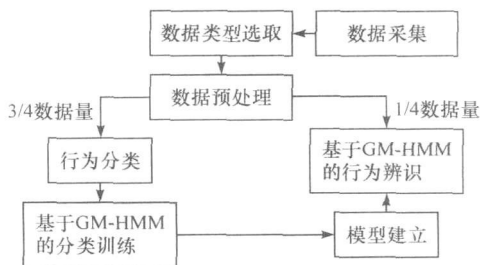


图3 基于GM-HMM的行为辨识基本流程图

3.1 数据类型的选取

从驾驶模拟器上实时采集的数据包括纵向速度与加速度、横向速度与加速度、垂向速度与加速度以及横摆角速度和俯仰角速度等。对于数据的采用不可能面面俱到,相关性很小的数据反而会起到减慢计算速度的作用。考虑到换道行为主要是一种横向趋变行为,因此,辨识用的数据类型主要是横向偏距(车辆至最右边车道线的距离)、横向速度、横向加速度、转向盘转角和横摆角速度。图4为采集的一段数据(车速维持在100 km/h左右)。




图4 数据类型的选取

3.2 行为分类及其训练

车辆在高速公路上行驶时,主要有两种驾驶行为(见图5):一是在本车道内保持行为(lane keeping LK),二是离开本车道的换道行为(lane changing LC)。因为只要车辆越过车道线就认为是要发生换道,所以这里引用文献[7]对换道的定义:换道是一种车辆向旁边车道运动而不反向的行为,任何在本车道内的途中反向都不是换道;换道在车辆越过车道线的那一瞬间结束。其中换道行为又分为向左换道(LCL)和向右换道(LCR)。




图5 车道保持与换道示意图

从图5可以看出,LC有明确的起始点和终止点。以3.2m的路宽为计,假定平均横向速度为0.64m/s,则换道时间(即图5中的LCR时间)至多为5s。然而LK没有明确的边界,换言之,车辆在本车道内做车道保持的时间并没有限制,LK时间长度可以很短,也可以很长。由于实验中LC时间长度基本上在2s左右,为了使时间长度基本相当,所以在这里取LK时间长度分别为1.2和3s,即相应地取车辆在高速状态下维持在本车道内的时间分别为1.2和3s。在后面的讨论中将分别对这3种不同的时间长度进行辨识以获得最好的辨识结果。

驾驶行为是一个连续过程,过程中某一时刻的状态往往只跟前一时刻的状态相关,因此,在这里采用从左至右的隐马尔可夫结构,即隐含状态只能传递给自身或者下一状态,而不能跨越式传递或反向传递,其中隐含状态数选择为6个。

对LK、LCI和LCR分别进行GM-HMM训练,可以得到相应的模型。以一种LK时间长度(LK size)和一种高斯混合数目(Gaussian mixture number,以下简称mix)为例进行训练,就可以得到GM-HMM_LK、GM-HMM_LCI和GM-HMM_LCR 3个模型。每个模型都有一个 λ_i 。

$$\lambda_i = (\pi, A, \zeta, \mu, \sum_j \lambda_j), i = 1, 2, 3 \quad (6)$$

3.3 行为辨识与分析

在建立3个行为模型的基础上,采用运动时间窗的形式对窗体内的行为进行辨识,如图6所示。窗体的宽度采用LK时间长度,窗体运动的间隔采

用 10 个采样间隔, 即 0.1 s。




图 6 运动时间窗

每个时间窗内的数据经 3 个模型辨识, 可以得到 3 个概率值, P_{IK} 、 P_{LCI} 和 P_{LCR} 。概率最大的就认为是相应行为。如在 $LK\ size=1$ s, $mix=4$ 时, 某一个时间窗下的辨识过程如表 1 所示。

表 1 某一时间窗下的辨识过程

| | 概率值 P | 辨识结果 |
|------------|----------|------|
| GM-HMM_IK | 1 798.04 | IK |
| GM-HMM_LCL | 846.82 | |
| GM-HMM_LCR | 1 127.05 | |

将辨识结果与实际情况进行比较, 即可得到辨识的准确度。下面对其中一段时间长度约为 20 s 的驾驶行为 (图 7) 进行运动时间窗形式的辨识。辨识准确率 $R = \frac{\text{准确辨识个数}}{\text{M时间窗个数 N}}$ 。以 $LK\ size=1$ s, $mix=4$ 为例, 时间窗长度为 1 s, 窗体运动间隔为 0.1 s, 则 20 s 时间长度的驾驶行为将有 191 个连续时间窗, 即 $N=191$, 其中每个时间窗采用表 1 的形式进行辨识, 如果辨识结果与实际情况一致, 则 M 计数加 1 (M 初始值设为 0), 否则加 0。随着窗体的运动, M 值进行累加, 在这里 $M=176$, 则辨识准确率 $R = \frac{M}{N} = 92.15\%$ 。具体的辨识结果见图 8。




图 7 待辨识的驾驶行为

从图 8 中可以看到, 辨识准确率普遍较高, 并且随着高斯混合数目的增大, 辨识准确率增大, 随着 LK 时间长度的增大, 辨识准确率也会提高。究其原因, 主要是高斯混合数目越多, 将固定时间窗内的数据分得越细, 数据间特征差异越突出; LK 时间长度越长, 车道保持的总体趋势越明显, 跟 LC 的分度




图 8 辨识结果

也越大。

在图 8 中, $LK\ size=3$ s, $mix=8$ 和 16 时, 辨识准确率都达到了 100%。但是两者在何时开始辨识出换道还存在差异。用与图 7 相对应的数据类型即图 9 来进行分析。图中小圆圈代表换道开始和结束的时刻, 换道开始时刻以向右转动转向盘, 横向距离开始变小为准, 换道结束时刻则以车辆越过中间道路线那一瞬间为准; 虚线方框代表 $mix=8$ 的时间窗, 实线方框代表 $mix=16$ 的时间窗, 每个时刻后面的数字代表各采样时间点。于是, 从换道开始到辨识出超车, $mix=8$ 和 $mix=16$ 两者的差异可见表 2。




图 9 $mix=8$ 和 $mix=16$ 的辨识差异

表 2 从换道开始到辨识出超车的时间长度 ^s

| | $mix=8$ | $mix=16$ |
|------|-----------------------------|-------------------------------|
| 时间长度 | $(23910 - 23810) / 100 = 1$ | $(23880 - 23810) / 100 = 0.7$ |

从表 2 中可以看到, $mix=16$ 时, 从换道开始到辨识出超车的时间长度更短, 说明模型更早地辨识出了此种驾驶行为是换道行为, 此时距换道结束还有 $(24\ 033 - 23\ 880) / 100 \approx 1.5$ s, 一旦此时的换道行为是不正常行为, 则能更早地给予驾驶员警告或者辅助纠正, 在提高驾驶安全性方面更有优势。

如前所述, 在辨识出右换道行为的同时, 检测出行车道内前方有车辆, 则判定此时的驾驶行为是超车行为。

3.4 对超车行为的分析

在辨识出超车行为后,有必要对该行为是正常或不正常超车行为进行判断分析。用驾驶模拟器在同一高速路段上采集5名驾驶员与超车相关的数据,主要包括辨识出超车时周围环境中其他车辆的情况,自车与前车的距离和自车的转向灯状态等。具体采集的路段与采集数据见图10和表3。




图10 辨识出超车时自车与周围环境的关系

表3 辨识出超车时自车状态
以及与周围环境的关系

| | 驾驶员 次数 | A | B | C | D | E |
|----------------------------|-----------|-------|-------|-------|-------|-------|
| | | | | | | |
| 与本车道 上前车的 距离/m | 1 | 51.32 | 39.01 | 53.01 | 45.74 | 37.15 |
| | 2 | 43.66 | 55.63 | 76.87 | 48.41 | 32.06 |
| | 3 | 53.71 | 37.09 | 55.20 | 53.97 | 31.96 |
| | 4 | 42.14 | 19.91 | 56.48 | 51.08 | 40.43 |
| 右转向灯 | 1 | 开 | 开 | 开 | 开 | 开 |
| | 2 | 开 | 开 | 开 | 开 | 开 |
| | 3 | 开 | 开 | 开 | 开 | 开 |
| | 4 | 开 | 开 | 开 | 开 | 关 |
| 侧后方超 车道上 是否有车辆 靠近 | 1 | 无 | 无 | 无 | 无 | 无 |
| | 2 | 无 | 无 | 有 | 无 | 无 |
| | 3 | 无 | 无 | 无 | 无 | 无 |
| | 4 | 无 | 无 | 无 | 无 | 无 |

从表3可以看到,驾驶员做出超车行为时离前车的距离往往都在自己习惯的一个范围内,所以只要设定一个范围,当小于这个范围而距离前车过近时,比如驾驶员B在第4次超车时与前车的距离仅为19.91m,超车过程中就有可能造成追尾碰撞等事

故,这时就有必要对驾驶员给予警告。另外,驾驶员C在第2次超车时侧后方超车道上有车辆靠近,以换道时间为2s,换道时车速为70km/h,侧后方超车道上车辆速度为110km/h来计算,这时换道超车与后车的安全距离应大于22.2m,若侧后方超车道上车辆距本车≤22.2m,会发生碰撞事故,所以这种超车行为是一种危险行为,也应给予警告或者辅助纠正。驾驶员E在第4次超车时没有开右转向灯,即使侧后方超车道上无车辆,也是一种危险驾驶行为,属驾驶员疲劳或者误操作所致,应给予警告。

4 结论

通过驾驶模拟器采集数据,利用高斯混合隐马尔可夫模型对高速公路上的超车行为进行了辨识。结果表明,只要选取合适的车道保持时间长度和高斯混合数目,辨识准确率能达到95%以上。针对超车时驾驶员有可能存在疲劳或者误操作,对5名驾驶员的超车行为进行了统计分析,一些不正常的超车行为如超车时自车距离本车道上的前车过近或者超车道上侧后方有其他车辆靠近,或自车没有开右转向灯,均能被有效识别,可用于警告驾驶员或者辅助纠正。

参考文献

[1] 李斌,王荣本,施树明,等.高速公路智能超车系统设计[J].IIS通讯,2000(2):44-52

[2] 游峰,王荣本,张荣辉,等.智能车辆换道与超车轨迹跟踪控制[J].农业机械学报,2008,39(6):42-45

[3] 李净达,潘宏侠,黄晋英.智能车辆超车系统模糊控制器设计[J].科技情报开发与经济,2007,17(6):174-175

[4] 邓金城,黄席樾,邓小丽,等.汽车防撞系统中的危险估计与超车决策[J].计算机仿真,2004,21(11):207-210

[5] Pentland A, Liu A. Modeling and Prediction of Human Behavior[J]. Neural Computation, 1999, 11(1): 229-242

[6] Lawrence R Rabiner. A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition[J]. Proceedings of the IEEE, 1989, 77(2): 257-286

[7] Salvucci D D. Inferring Driver Intent: A Case Study in Lane-change Detection[J]. in Proc. Human Factors/Ergonomics Soc. 48th Annu. Meeting, 2004: 2228-2231.